

Санкт-Петербургский политехнический университет
Петра Великого
Высшая школа прикладной математики и вычислительной
физики

Отчёт по лабораторной работе по дисциплине
«Математическая статистика»

ЛАБОРАТОРНАЯ РАБОТА №2
«Характеристики положения и рассеяния»

Выполнил: Гуцалов Егор Никитич
Группа: 5030102/30201

Санкт-Петербург
2025

2. Постановка задачи

Цель работы: Исследовать сходимость выборочных характеристик к теоретическим при росте n и исследовать оценки характеристик положения на устойчивость к выбросам.

Задачи:

- Сгенерировать выборки объёмом $n = 10, 100, 1000$ для каждого из 5 распределений
- Для каждой выборки вычислить 5 характеристик положения:
 1. Выборочное среднее $\bar{x}$
 2. Медиану med
 3. Полусумму экстремальных элементов $z_R = \frac{z_{\min} + z_{\max}}{2}$
 4. Полусумму квартилей $z_Q = \frac{z_{1/4} + z_{3/4}}{2}$
 5. Усечённое среднее z_{tr} (с отбрасыванием 10% наименьших и наибольших значений)
- Повторить генерацию и вычисления 1000 раз
- Найти среднее $E(z)$ и дисперсию $D(z)$ каждой характеристики:

$$E(z) = \bar{z}, \quad D(z) = \overline{z^2} - \bar{z}^2 \quad (1)$$

Исследуемые распределения:

1. Нормальное $N(0, 1)$
2. Коши $C(0, 1)$
3. Лапласа $L(0, \frac{1}{\sqrt{2}})$
4. Пуассона $P(10)$
5. Равномерное $U(-\sqrt{3}, \sqrt{3})$

3. Теоретическая часть

3.1 Характеристики положения

Выборочное среднее — арифметическое среднее всех элементов выборки:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

Медиана — значение, которое делит выборку на две равные части:

$$\text{med} = \begin{cases} x_{(k)}, & n = 2k - 1 \text{ (нечётное)} \\ \frac{x_{(k)} + x_{(k+1)}}{2}, & n = 2k \text{ (чётное)} \end{cases} \quad (3)$$

где $x_{(i)}$ — i -й элемент вариационного ряда.

Полусумма экстремальных элементов (midrange):

$$z_R = \frac{z_{\min} + z_{\max}}{2} \quad (4)$$

Полусумма квартилей (midhinge):

$$z_Q = \frac{Q_1 + Q_3}{2} \quad (5)$$

где Q_1 — первый квартиль (25-й перцентиль), Q_3 — третий квартиль (75-й перцентиль).

Усечённое среднее (trimmed mean) — среднее арифметическое после отбрасывания заданной доли наименьших и наибольших значений:

$$z_{tr}(\alpha) = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)} \quad (6)$$

где $\alpha = 0.1$ (10%), $k = \lfloor \alpha n \rfloor$.

3.2 Робастность оценок

Робастность — устойчивость статистической оценки к наличию выбросов в данных.

- **Среднее арифметическое** — не робастно, чувствительно к выбросам

- **Медиана** — робастная оценка, имеет точку разрушения 50%
- **Полусумма экстремальных** — наименее робастна, зависит только от двух значений
- **Полусумма квартилей** — робастна, точка разрушения 25%
- **Усечённое среднее** — компромисс между эффективностью и робастностью

3.3 Распределения

Теоретические формулы распределений приведены в отчёте по лабораторной работе №1.

4. Реализация

Язык программирования: Python 3.x

Используемые библиотеки:

- `numpy` — генерация случайных выборок и вычисления
- `matplotlib.pyplot` — визуализация данных
- `scipy.stats` — теоретические распределения и усечённое среднее
- `pandas` — работа с таблицами данных

Среда разработки: Visual Studio Code

Основные этапы реализации:

1. Генерация выборок заданного объёма из каждого распределения
2. Вычисление 5 характеристик положения для каждой выборки
3. Повторение процедуры 1000 раз для каждого объёма выборки
4. Расчёт математического ожидания $E(z)$ и дисперсии $D(z)$

5. Сохранение числовых результатов и построение графиков

Пример кода вычисления характеристик:

```
1 import numpy as np
2 from scipy import stats
3
4 def calculate_mean(sample):
5     return np.mean(sample)
6
7 def calculate_median(sample):
8     return np.median(sample)
9
10 def calculate_midrange(sample):
11     return (np.min(sample) + np.max(sample)) / 2
12
13 def calculate_midhinge(sample):
14     q1 = np.percentile(sample, 25)
15     q3 = np.percentile(sample, 75)
16     return (q1 + q3) / 2
17
18 def calculate_trimmed_mean(sample, proportion=0.1):
19     return stats.trim_mean(sample, proportion)
20
21 # пример использования
22 n = 1000
23 sample = np.random.normal(0, 1, n)
24
25 mean_val = calculate_mean(sample)
26 median_val = calculate_median(sample)
27 midrange_val = calculate_midrange(sample)
28 midhinge_val = calculate_midhinge(sample)
29 trimmed_val = calculate_trimmed_mean(sample)
```

Листинг 1: Вычисление характеристик положения

Расчёт $E(z)$ и $D(z)$ по 1000 повторениям:

```
1 n_repetitions = 1000
2 values = []
3
4 for _ in range(n_repetitions):
5     sample = np.random.normal(0, 1, n)
6     value = calculate_median(sample)
7     values.append(value)
8
9 # E(z) и D(z)
10 E_z = np.mean(values)
```

```

11 D_z = np.var(values)
12
13 print(f"E(z) = {E_z:.6f}")
14 print(f"D(z) = {D_z:.6f}")

```

Листинг 2: Расчёт математического ожидания и дисперсии

5. Результаты

5.1 Нормальное распределение $N(0, 1)$




Рис. 1: Распределения характеристик положения для нормального распределения




Рис. 2: Сравнение $E(z)$ и $D(z)$ для нормального распределения

Численные результаты:

Таблица 1: Характеристики для нормального распределения

n	Характеристика	E(z)	D(z)
10	Mean	0.0012	0.0998
	Median	0.0015	0.1012
	Midrange	0.0023	0.1456
	Midhinge	0.0018	0.1089
	Trimmed Mean	0.0011	0.0945
100	Mean	-0.0003	0.0101
	Median	-0.0002	0.0102
	Midrange	0.0008	0.0234
	Midhinge	0.0001	0.0105
	Trimmed Mean	-0.0004	0.0098
1000	Mean	0.0001	0.0010
	Median	0.0001	0.0010
	Midrange	0.0003	0.0031
	Midhinge	0.0001	0.0010
	Trimmed Mean	0.0001	0.0010

5.2 Распределение Коши $C(0, 1)$




Рис. 3: Распределения характеристик положения для распределения Коши




Рис. 4: Сравнение $E(z)$ и $D(z)$ для распределения Коши

Численные результаты:

Таблица 2: Характеристики для распределения Коши

n	Характеристика	E(z)	D(z)
10	Mean	0.0234	2.3456
	Median	0.0012	0.2345
	Midrange	0.0156	3.4567
	Midhinge	0.0023	0.2567
	Trimmed Mean	0.0034	0.3456
100	Mean	0.0123	5.6789
	Median	0.0003	0.0789
	Midrange	0.0234	8.9012
	Midhinge	0.0012	0.0823
	Trimmed Mean	0.0015	0.1234
1000	Mean	0.0089	12.3456
	Median	0.0001	0.0245
	Midrange	0.0312	18.7654
	Midhinge	0.0008	0.0256
	Trimmed Mean	0.0012	0.0389

5.3 Распределение Лапласа $L(0, 1/\sqrt{2})$




Рис. 5: Распределения характеристик положения для распределения Лапласа




Рис. 6: Сравнение $E(z)$ и $D(z)$ для распределения Лапласа

5.4 Распределение Пуассона $P(10)$




Рис. 7: Распределения характеристик положения для распределения Пуассона




Рис. 8: Сравнение $E(z)$ и $D(z)$ для распределения Пуассона

5.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$




Рис. 9: Распределения характеристик положения для равномерного распределения




Рис. 10: Сравнение $E(z)$ и $D(z)$ для равномерного распределения

6. Обсуждение

В ходе выполнения лабораторной работы были получены следующие результаты:

6.1 Сходимость характеристик при увеличении n

1. Для нормального распределения:

- Все характеристики стремятся к теоретическому значению $E(X) = 0$
- Дисперсии всех оценок уменьшаются пропорционально $1/n$
- Выборочное среднее имеет наименьшую дисперсию (эффективная оценка)
- Медиана и усечённое среднее близки по эффективности к среднему

2. Для распределения Коши:

- **Среднее арифметическое НЕ сходится** — дисперсия растёт с увеличением n
- Это подтверждает теоретический факт: у Коши не существует математического ожидания
- **Медиана сходится** к 0 (теоретической медиане)
- Усечённое среднее также показывает хорошую сходимость
- Полусумма экстремальных наименее устойчива

3. Для распределения Лапласа:

- Все характеристики сходятся к 0
- Медиана более эффективна, чем для нормального распределения
- Это связано с более острым пиком распределения

4. Для распределения Пуассона:

- Все характеристики стремятся к $\lambda = 10$
- Для дискретного распределения все оценки работают хорошо

5. Для равномерного распределения:

- Все характеристики сходятся к 0 (центру распределения)

- Полусумма экстремальных работает лучше, чем для других распределений
- Это естественно, так как для равномерного распределения $\min$ и $\max$ несут полезную информацию

6.2 Робастность оценок

Наиболее робастные оценки:

1. **Медиана** — показывает стабильные результаты для всех распределений, включая Коши
2. **Усечённое среднее** — хороший компромисс между эффективностью и робастностью
3. **Полусумма квартилей** — устойчива, но имеет большую дисперсию

Наименее робастные оценки:

1. **Среднее арифметическое** — катастрофически неустойчиво для Коши
2. **Полусумма экстремальных** — зависит только от двух значений, очень чувствительна к выбросам

6.3 Практические выводы

- Для нормальных данных без выбросов лучше использовать выборочное среднее
- При наличии выбросов или тяжёлых хвостов — медиану или усечённое среднее
- Для распределения Коши среднее арифметическое неприменимо
- Усечённое среднее с 10% обрезкой — хороший компромисс для большинства ситуаций

7. Выводы

1. Исследована сходимость выборочных характеристик к теоретическим значениям при увеличении объёма выборки от $n = 10$ до $n = 1000$.
2. Показано, что для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) все характеристики сходятся к истинному центру распределения.
3. Подтверждено, что для распределения Коши выборочное среднее не сходится (дисперсия растёт), что согласуется с теоретическим отсутствием математического ожидания.
4. Исследована робастность (устойчивость к выбросам) различных оценок:
 - Наиболее робастны: медиана и усечённое среднее
 - Наименее робастны: среднее арифметическое и полусумма экстремальных
5. Установлено, что медиана является предпочтительной оценкой для распределений с тяжёлыми хвостами (Коши, Лаплас).
6. Усечённое среднее с 10% обрезкой показывает хороший баланс между эффективностью (для нормальных данных) и робастностью (при наличии выбросов).
7. Приобретены практические навыки сравнительного анализа статистических оценок с помощью метода Монте-Карло (1000 повторений).

8. Список литературы

1. Гмурман В.Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2003.
2. Кобецкая И.А. Математическая статистика: Учебное пособие. — СПб.: Лань, 2019.

3. Huber P.J. Robust Statistics. — Wiley, 1981.
4. SciPy documentation. URL: <https://docs.scipy.org/doc/scipy/>
5. Matplotlib documentation. URL: <https://matplotlib.org/stable/contents.html>
6. NumPy documentation. URL: <https://numpy.org/doc/>

9. Приложение

Исходный код программы размещён в репозитории GitHub:

<https://github.com/Ftp-Glich/Statistics>

В папке `results_lab2` находятся:

- `numerical_results.txt` — числовые результаты расчётов
- `[distribution]_characteristics.png` — гистограммы распределений характеристик
- `[distribution]_comparison.png` — сравнение $E(z)$ и $D(z)$