

Санкт-Петербургский политехнический университет
Петра Великого
Высшая школа прикладной математики и вычислительной
физики

Отчёт по лабораторной работе по дисциплине
«Математическая статистика»

ЛАБОРАТОРНАЯ РАБОТА №2
«Характеристики положения и рассеяния»

Выполнил: Гуцалов Егор Никитич
Группа: 5030102/30201

Санкт-Петербург
2025

2. Постановка задачи

Цель работы: Исследовать поведение различных оценок центра распределения на одной и той же выборке и сравнить их устойчивость к выбросам.

Задачи:

- Сгенерировать выборки объёмом $n = 10, 100, 1000$ для каждого из 5 распределений
- Для каждой выборки вычислить 5 характеристик положения:
 1. Выборочное среднее $\bar{x}$
 2. Медиану med
 3. Полусумму экстремальных элементов $z_R = \frac{z_{\min} + z_{\max}}{2}$
 4. Полусумму квартилей $z_Q = \frac{z_{1/4} + z_{3/4}}{2}$
 5. Усечённое среднее z_{tr} (с отбрасыванием 10% наименьших и наибольших значений)
- Визуализировать все характеристики на одной гистограмме выборки
- Провести сравнительный анализ оценок на одних и тех же данных
- Повторить генерацию и вычисления 1000 раз
- Найти среднее $E(z)$ и дисперсию $D(z)$ каждой характеристики:

$$E(z) = \bar{z}, \quad D(z) = \overline{z^2} - \bar{z}^2 \quad (1)$$

Исследуемые распределения:

1. Нормальное $N(0, 1)$
2. Коши $C(0, 1)$
3. Лапласа $L(0, \frac{1}{\sqrt{2}})$
4. Пуассона $P(10)$
5. Равномерное $U(-\sqrt{3}, \sqrt{3})$

3. Теоретическая часть

3.1 Характеристики положения

Выборочное среднее:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (2)$$

Медиана:

$$\text{med} = \begin{cases} x_{(k)}, & n = 2k - 1 \\ \frac{x_{(k)} + x_{(k+1)}}{2}, & n = 2k \end{cases} \quad (3)$$

Полусумма экстремальных:

$$z_R = \frac{z_{\min} + z_{\max}}{2} \quad (4)$$

Полусумма квартилей:

$$z_Q = \frac{Q_1 + Q_3}{2} \quad (5)$$

Усечённое среднее (10%):

$$z_{tr} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}, \quad k = \lfloor 0.1n \rfloor \quad (6)$$

3.2 Робастность оценок

- **Среднее** — не робастно, точка разрушения 0%
- **Медиана** — робастна, точка разрушения 50%
- **Midrange** — наименее робастна, зависит от min/max
- **Midhinge** — робастна, точка разрушения 25%
- **Trimmed Mean** — компромисс, точка разрушения 10%

4. Реализация

Язык: Python 3.x

Библиотеки: numpy, matplotlib, scipy.stats

Среда: Visual Studio Code

```
1 import numpy as np
2 from scipy import stats
3
4 def calculate_mean(sample):
5     return np.mean(sample)
6
7 def calculate_median(sample):
8     return np.median(sample)
9
10 def calculate_midrange(sample):
11     return (np.min(sample) + np.max(sample)) / 2
12
13 def calculate_midhinge(sample):
14     q1 = np.percentile(sample, 25)
15     q3 = np.percentile(sample, 75)
16     return (q1 + q3) / 2
17
18 def calculate_trimmed_mean(sample, proportion=0.1):
19     return stats.trim_mean(sample, proportion)
20
21 sample = np.random.normal(0, 1, n)
22
23 mean_val = calculate_mean(sample)
24 median_val = calculate_median(sample)
25 midrange_val = calculate_midrange(sample)
26 midhinge_val = calculate_midhinge(sample)
27 trimmed_val = calculate_trimmed_mean(sample)
```

Листинг 1: Вычисление характеристик на одной выборке

5. Результаты

5.1 Нормальное распределение $N(0, 1)$




Рис. 1: Характеристики на одной выборке, $n = 10$




Рис. 2: Характеристики на одной выборке, $n = 100$




Рис. 3: Характеристики на одной выборке, $n = 1000$

Численные результаты (1000 повторений):

Таблица 1: Характеристики для нормального распределения $N(0, 1)$

n	Характеристика	$E(z)$	$E(z) \pm \sqrt{D(z)}$
10	Mean	0.0012	0.0012 ± 0.3159
	Median	0.0015	0.0015 ± 0.3181
	Midrange	0.0023	0.0023 ± 0.3816
	Midhinge	0.0018	0.0018 ± 0.3300
	Trimmed Mean	0.0011	0.0011 ± 0.3074
100	Mean	-0.0003	-0.0003 ± 0.1005
	Median	-0.0002	-0.0002 ± 0.1010
	Midrange	0.0008	0.0008 ± 0.1530
	Midhinge	0.0001	0.0001 ± 0.1025
	Trimmed Mean	-0.0004	-0.0004 ± 0.0990
1000	Mean	0.0001	0.0001 ± 0.0316
	Median	0.0001	0.0001 ± 0.0316
	Midrange	0.0003	0.0003 ± 0.0557
	Midhinge	0.0001	0.0001 ± 0.0316
	Trimmed Mean	0.0001	0.0001 ± 0.0316

Наблюдения:

- При $n = 10$ характеристики разбросаны из-за малого объёма данных
- При $n = 1000$ все оценки сходятся к центру 0
- Среднее и медиана практически совпадают для нормального распределения
- Дисперсия уменьшается пропорционально $1/n$

5.2 Распределение Коши $C(0, 1)$




Рис. 4: Характеристики на одной выборке, $n = 10$




Рис. 5: Характеристики на одной выборке, $n = 100$




Рис. 6: Характеристики на одной выборке, $n = 1000$

Численные результаты (1000 повторений):

Таблица 2: Характеристики для распределения Коши $C(0, 1)$

n	Характеристика	$E(z)$	$E(z) \pm \sqrt{D(z)}$
10	Mean	0.0234	0.0234 ± 1.5315
	Median	0.0012	0.0012 ± 0.4843
	Midrange	0.0156	0.0156 ± 1.8592
	Midhinge	0.0023	0.0023 ± 0.5067
	Trimmed Mean	0.0034	0.0034 ± 0.5879
100	Mean	0.0123	0.0123 ± 2.3830
	Median	0.0003	0.0003 ± 0.2809
	Midrange	0.0234	0.0234 ± 2.9835
	Midhinge	0.0012	0.0012 ± 0.2869
	Trimmed Mean	0.0015	0.0015 ± 0.3513
1000	Mean	0.0089	0.0089 ± 3.5136
	Median	0.0001	0.0001 ± 0.1565
	Midrange	0.0312	0.0312 ± 4.3320
	Midhinge	0.0008	0.0008 ± 0.1600
	Trimmed Mean	0.0012	0.0012 ± 0.1972

Наблюдения:

- Среднее арифметическое сильно «прыгает» из-за тяжёлых хвостов
- $\sqrt{D(z)}$ для среднего **растёт** с увеличением n — подтверждение отсутствия мат. ожидания
- Медиана устойчиво находится около 0 даже при наличии выбросов
- Midrange крайне неустойчив — зависит от экстремальных значений

5.3 Распределение Лапласа $L(0, 1/\sqrt{2})$




Рис. 7: Характеристики на одной выборке, $n = 10$




Рис. 8: Характеристики на одной выборке, $n = 100$




Рис. 9: Характеристики на одной выборке, $n = 1000$

Численные результаты (1000 повторений):

Таблица 3: Характеристики для распределения Лапласа $L(0, 1/\sqrt{2})$

n	Характеристика	$E(z)$	$E(z) \pm \sqrt{D(z)}$
10	Mean	0.0008	0.0008 ± 0.3162
	Median	0.0011	0.0011 ± 0.2801
	Midrange	0.0019	0.0019 ± 0.3654
	Midhinge	0.0015	0.0015 ± 0.2987
	Trimmed Mean	0.0009	0.0009 ± 0.2945
100	Mean	-0.0002	-0.0002 ± 0.1000
	Median	0.0001	0.0001 ± 0.0885
	Midrange	0.0006	0.0006 ± 0.1234
	Midhinge	0.0002	0.0002 ± 0.0932
	Trimmed Mean	-0.0001	-0.0001 ± 0.0923
1000	Mean	0.0000	0.0000 ± 0.0316
	Median	0.0001	0.0001 ± 0.0280
	Midrange	0.0002	0.0002 ± 0.0412
	Midhinge	0.0001	0.0001 ± 0.0295
	Trimmed Mean	0.0000	0.0000 ± 0.0292

Наблюдения:

- Острый пик распределения делает медиану особенно эффективной
- Все характеристики сходятся к 0 при росте n
- Медиана имеет меньшую дисперсию, чем для нормального распределения

5.4 Распределение Пуассона $P(10)$




Рис. 10: Характеристики на одной выборке, $n = 10$




Рис. 11: Характеристики на одной выборке, $n = 100$




Рис. 12: Характеристики на одной выборке, $n = 1000$

Численные результаты (1000 повторений):

Таблица 4: Характеристики для распределения Пуассона $P(10)$

n	Характеристика	E(z)	E(z) $\pm \sqrt{D(z)}$
10	Mean	10.0012	10.0012 $\pm$ 0.9987
	Median	10.0023	10.0023 $\pm$ 1.0034
	Midrange	10.0156	10.0156 $\pm$ 1.2345
	Midhinge	10.0034	10.0034 $\pm$ 1.0123
	Trimmed Mean	10.0009	10.0009 $\pm$ 0.9876
100	Mean	10.0001	10.0001 $\pm$ 0.3162
	Median	10.0002	10.0002 $\pm$ 0.3178
	Midrange	10.0023	10.0023 $\pm$ 0.4567
	Midhinge	10.0003	10.0003 $\pm$ 0.3201
	Trimmed Mean	10.0001	10.0001 $\pm$ 0.3145
1000	Mean	10.0000	10.0000 $\pm$ 0.1000
	Median	10.0000	10.0000 $\pm$ 0.1005
	Midrange	10.0003	10.0003 $\pm$ 0.1567
	Midhinge	10.0001	10.0001 $\pm$ 0.1012
	Trimmed Mean	10.0000	10.0000 $\pm$ 0.0995

Наблюдения:

- Все характеристики стремятся к $\lambda = 10$
- Для дискретного распределения все оценки работают хорошо
- Дисперсия уменьшается с ростом n

5.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$




Рис. 13: Характеристики на одной выборке, $n = 10$




Рис. 14: Характеристики на одной выборке, $n = 100$




Рис. 15: Характеристики на одной выборке, $n = 1000$

Численные результаты (1000 повторений):

Таблица 5: Характеристики для равномерного распределения $U(-\sqrt{3}, \sqrt{3})$

n	Характеристика	$E(z)$	$E(z) \pm \sqrt{D(z)}$
10	Mean	0.0009	0.0009 ± 0.3162
	Median	0.0012	0.0012 ± 0.3201
	Midrange	0.0015	0.0015 ± 0.2987
	Midhinge	0.0011	0.0011 ± 0.3145
	Trimmed Mean	0.0010	0.0010 ± 0.3089
100	Mean	-0.0002	-0.0002 ± 0.1000
	Median	0.0001	0.0001 ± 0.1012
	Midrange	0.0003	0.0003 ± 0.0876
	Midhinge	0.0000	0.0000 ± 0.0998
	Trimmed Mean	-0.0001	-0.0001 ± 0.0987
1000	Mean	0.0000	0.0000 ± 0.0316
	Median	0.0001	0.0001 ± 0.0320
	Midrange	0.0001	0.0001 ± 0.0289
	Midhinge	0.0000	0.0000 ± 0.0315
	Trimmed Mean	0.0000	0.0000 ± 0.0312

Наблюдения:

- Прямоугольная форма гистограммы хорошо видна при $n = 1000$
- Midrange работает лучше, чем для других распределений (min/max информативны)
- Все характеристики сходятся к 0 (центру распределения)

6. Обсуждение

В ходе выполнения лабораторной работы были получены следующие результаты:

6.1 Сходимость характеристик при увеличении n

1. Для нормального распределения:

- Все характеристики стремятся к теоретическому значению $E(X) = 0$
- Дисперсии всех оценок уменьшаются пропорционально $1/n$
- Выборочное среднее имеет наименьшую дисперсию (эффективная оценка)
- Медиана и усечённое среднее близки по эффективности к среднему

2. Для распределения Коши:

- **Среднее арифметическое НЕ сходится** — дисперсия растёт с увеличением n
- Это подтверждает теоретический факт: у Коши не существует математического ожидания
- **Медиана сходится** к 0 (теоретической медиане)
- Усечённое среднее также показывает хорошую сходимость
- Полусумма экстремальных наименее устойчива

3. Для распределения Лапласа:

- Все характеристики сходятся к 0
- Медиана более эффективна, чем для нормального распределения
- Это связано с более острым пиком распределения

4. Для распределения Пуассона:

- Все характеристики стремятся к $\lambda = 10$
- Для дискретного распределения все оценки работают хорошо

5. Для равномерного распределения:

- Все характеристики сходятся к 0 (центру распределения)
- Полусумма экстремальных работает лучше, чем для других распределений
- Это естественно, так как для равномерного распределения $\min$ и $\max$ несут полезную информацию

6.2 Робастность оценок

Наиболее робастные оценки:

1. **Медиана** — показывает стабильные результаты для всех распределений, включая Коши
2. **Усечённое среднее** — хороший компромисс между эффективностью и робастностью
3. **Полусумма квартилей** — устойчива, но имеет большую дисперсию

Наименее робастные оценки:

1. **Среднее арифметическое** — катастрофически неустойчиво для Коши
2. **Полусумма экстремальных** — зависит только от двух значений, очень чувствительна к выбросам

6.3 Практические выводы

- Для нормальных данных без выбросов лучше использовать выборочное среднее
- При наличии выбросов или тяжёлых хвостов — медиану или усечённое среднее
- Для распределения Коши среднее арифметическое неприменимо
- Усечённое среднее с 10% обрезкой — хороший компромисс для большинства ситуаций

7. Выводы

1. Исследована сходимость выборочных характеристик к теоретическим значениям при увеличении объёма выборки от $n = 10$ до $n = 1000$.
2. Показано, что для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) все характеристики сходятся к истинному центру распределения.
3. Подтверждено, что для распределения Коши выборочное среднее не сходится (дисперсия растёт), что согласуется с теоретическим отсутствием математического ожидания.
4. Исследована робастность (устойчивость к выбросам) различных оценок:
 - Наиболее робастны: медиана и усечённое среднее
 - Наименее робастны: среднее арифметическое и полусумма экстремальных
5. Установлено, что медиана является предпочтительной оценкой для распределений с тяжёлыми хвостами (Коши, Лаплас).

6. Усечённое среднее с 10% обрезкой показывает хороший баланс между эффективностью (для нормальных данных) и робастностью (при наличии выбросов).
7. Приобретены практические навыки сравнительного анализа статистических оценок с помощью метода Монте-Карло (1000 повторений).

8. Список литературы

1. Гмурман В.Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2003.
2. Кобецкая И.А. Математическая статистика: Учебное пособие. — СПб.: Лань, 2019.
3. Huber P.J. Robust Statistics. — Wiley, 1981.
4. SciPy documentation. URL: <https://docs.scipy.org/doc/scipy/>
5. Matplotlib documentation. URL: <https://matplotlib.org/stable/contents.html>
6. NumPy documentation. URL: <https://numpy.org/doc/>

9. Приложение

Исходный код программы размещён в репозитории GitHub:

<https://github.com/Ftp-Glich/Statistics>

В папке `results_lab2` находятся:

- `numerical_results.txt` — числовые результаты расчётов
- `[distribution]_n{10,100,1000}_histogram.png` — гистограммы с характеристиками