

Санкт-Петербургский политехнический университет
Петра Великого
Высшая школа прикладной математики и вычислительной
физики

Отчёт по лабораторной работе по дисциплине
«Математическая статистика»

ЛАБОРАТОРНАЯ РАБОТА №3
«Боксплот Тьюки и анализ выбросов»

Выполнил: Гуцалов Егор Никитич
Группа: 5030102/30201

Санкт-Петербург
2025

2. Постановка задачи

Цель работы: Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений, проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Задачи:

- Сгенерировать выборки объёмом $n = 20, 100$ для каждого из 5 распределений
- Построить боксплот Тьюки для каждой выборки
- Определить долю выбросов экспериментально
- Повторить генерацию и вычисления 1000 раз для каждого распределения
- Вычислить среднюю долю выбросов и проанализировать результаты

Исследуемые распределения:

1. Нормальное $N(0, 1)$
2. Коши $C(0, 1)$
3. Лапласа $L(0, \frac{1}{\sqrt{2}})$
4. Пуассона $P(10)$
5. Равномерное $U(-\sqrt{3}, \sqrt{3})$

3. Теоретическая часть

3.1 Боксплот Тьюки

Боксплот (ящик с усами) — это графический метод визуализации распределения данных, предложенный Джоном Тьюки. Он показывает пять числовых характеристик:

- Минимальное значение (нижний ус)

- Первый квартиль Q_1 (25-й перцентиль)
- Медиану Q_2 (50-й перцентиль)
- Третий квартиль Q_3 (75-й перцентиль)
- Максимальное значение (верхний ус)

3.2 Квартили и межквартильный размах

Квартили делят упорядоченную выборку на четыре равные части:

$$Q_1 : 25\% \text{ данных меньше этого значения} \quad (1)$$

$$Q_2 = \text{med} : 50\% \text{ данных меньше этого значения (медиана)} \quad (2)$$

$$Q_3 : 75\% \text{ данных меньше этого значения} \quad (3)$$

Межквартильный размах (IQR — InterQuartile Range):

$$IQR = Q_3 - Q_1 \quad (4)$$

3.3 Определение выбросов по методу Тьюки

Согласно правилу Тьюки, **выбросами** считаются значения, выходящие за пределы:

$$\text{Нижняя граница} = Q_1 - 1.5 \cdot IQR \quad (5)$$

$$\text{Верхняя граница} = Q_3 + 1.5 \cdot IQR \quad (6)$$

То есть выбросы — это значения x , для которых:

$$x < Q_1 - 1.5 \cdot IQR \quad \text{или} \quad x > Q_3 + 1.5 \cdot IQR \quad (7)$$

3.4 Доля выбросов

Доля выбросов вычисляется как отношение количества выбросов к общему объёму выборки:

$$\text{Доля выбросов} = \frac{\text{Количество выбросов}}{n} \quad (8)$$

3.5 Почему коэффициент 1.5?

Коэффициент 1.5 выбран эмпирически:

- Для нормального распределения это даёт примерно 0.7% выбросов
- Это компромисс между чувствительностью и устойчивостью
- Позволяет обнаруживать умеренные аномалии, не отбрасывая нормальные данные

4. Реализация

Язык программирования: Python 3.x

Используемые библиотеки:

- `numpy` — генерация случайных выборок и вычисления
- `matplotlib.pyplot` и `seaborn` — визуализация данных
- `scipy.stats` — теоретические распределения

Среда разработки: Visual Studio Code

Основные этапы реализации:

1. Генерация выборок заданного объёма из каждого распределения
2. Вычисление квартилей Q_1 , Q_3 и IQR
3. Определение границ выбросов по формулам Тьюки
4. Подсчёт количества и доли выбросов

5. Построение боксплотов

6. Повторение 1000 раз для получения устойчивых оценок

7. Расчёт средней доли выбросов для каждого распределения

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4 from scipy import stats
5
6 def calculate_outliers_tukey(sample):
7     Q1 = np.percentile(sample, 25)
8     Q3 = np.percentile(sample, 75)
9     IQR = Q3 - Q1
10
11     lower_bound = Q1 - 1.5 * IQR
12     upper_bound = Q3 + 1.5 * IQR
13
14     outliers = sample[(sample < lower_bound) | (sample > upper_bound)]
15     outlier_ratio = len(outliers) / len(sample)
16
17     return outliers, outlier_ratio
18
19 n_repetitions = 1000
20 sample_sizes = [20, 100]
21
22 for dist_name in distributions:
23     for n in sample_sizes:
24         outlier_ratios = []
25
26         for rep in range(n_repetitions):
27             sample = generate_sample(dist_name, n)
28             _, ratio = calculate_outliers_tukey(sample)
29             outlier_ratios.append(ratio)
30
31         avg_ratio = np.mean(outlier_ratios)
32         std_ratio = np.std(outlier_ratios)
```

Листинг 1: Вычисление выбросов по методу Тьюки

5. Результаты

5.1 Нормальное распределение $N(0, 1)$




Рис. 1: Боксплоты Тьюки для нормального распределения

Наблюдения:

- При $n = 20$ наблюдается несколько выбросов
- При $n = 100$ выбросов меньше, распределение более симметрично
- Медиана близка к 0 (теоретическому значению)

5.2 Распределение Коши $C(0, 1)$




Рис. 2: Боксплоты Тьюки для распределения Коши

Наблюдения:

- Очень много выбросов из-за тяжёлых хвостов
- Ящик шире, чем у нормального распределения
- Выбросы могут быть очень далёкими от центра

5.3 Распределение Лапласа $L(0, 1/\sqrt{2})$




Рис. 3: Боксплоты Тьюки для распределения Лапласа

Наблюдения:

- Больше выбросов, чем у нормального, но меньше, чем у Коши
- Острый пик в центре

5.4 Распределение Пуассона $P(10)$




Рис. 4: Боксплоты Тьюки для распределения Пуассона

Наблюдения:

- Дискретное распределение (ступенчатая структура)
- Небольшое количество выбросов
- Асимметрия вправо

5.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$




Рис. 5: Боксплоты Тьюки для равномерного распределения

Наблюдения:

- Практически нет выбросов
- Симметричное распределение
- Ящик занимает большую часть диапазона

5.6 Теоретический расчёт доли выбросов по правилу Тьюки

Для метода Тьюки с коэффициентом $1.5 \cdot IQR$ можно аналитически вычислить теоретическую долю выбросов для каждого распределения.

Общая формула:

$$P_{\text{out}} = P(X < Q_1 - 1.5 \cdot IQR) + P(X > Q_3 + 1.5 \cdot IQR) \quad (9)$$

Нормальное распределение $N(0, 1)$

$$Q_1 = \Phi^{-1}(0.25) \approx -0.6745$$

$$Q_3 = \Phi^{-1}(0.75) \approx 0.6745$$

$$IQR = Q_3 - Q_1 \approx 1.349$$

$$\text{Границы: } [-2.698, 2.698]$$

$$P_{\text{out}} = 2 \cdot \Phi(-2.698) \approx 2 \cdot 0.0035 = \mathbf{0.70\%}$$

Распределение Коши $C(0, 1)$

Функция распределения: $F(x) = \frac{1}{\pi} \arctan(x) + \frac{1}{2}$

$$Q_1 = \tan(\pi(0.25 - 0.5)) = -1$$

$$Q_3 = \tan(\pi(0.75 - 0.5)) = 1$$

$$IQR = 2$$

$$\text{Границы: } [-4, 4]$$

$$\begin{aligned} P_{\text{out}} &= 2 \cdot (1 - F(4)) = 2 \cdot \left(\frac{1}{2} - \frac{1}{\pi} \arctan(4) \right) \\ &\approx 2 \cdot (0.5 - 0.422) = \mathbf{15.6\%} \end{aligned}$$

Распределение Лапласа $L(0, 1/\sqrt{2})$

Параметр масштаба: $b = 1/\sqrt{2} \approx 0.7071$

$$Q_1 = -b \ln(2) \approx -0.490$$

$$Q_3 = b \ln(2) \approx 0.490$$

$$IQR = 2b \ln(2) \approx 0.980$$

$$\text{Границы: } [-1.960, 1.960]$$

$$\begin{aligned} P_{\text{out}} &= 2 \cdot 0.5 \cdot e^{-1.960/b} = e^{-1.960/0.7071} \\ &\approx e^{-2.772} \approx \mathbf{6.2\%} \end{aligned}$$

Распределение Пуассона $P(10)$

Для дискретного распределения используем нормальную аппроксимацию $N(\lambda, \lambda)$:

$$\mu = \lambda = 10, \quad \sigma = \sqrt{10} \approx 3.162$$

$$Q_1 \approx 10 - 0.6745 \cdot 3.162 \approx 7.87$$

$$Q_3 \approx 10 + 0.6745 \cdot 3.162 \approx 12.13$$

$$IQR \approx 4.26$$

$$\text{Границы: } [1.48, 18.52]$$

$$P_{\text{out}} \approx 2 \cdot \Phi\left(\frac{1.48 - 10}{3.162}\right) \approx \mathbf{0.7\%}$$

Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

$$\text{Диапазон: } [-\sqrt{3}, \sqrt{3}] \approx [-1.732, 1.732]$$

$$Q_1 = -\sqrt{3}/2 \approx -0.866, \quad Q_3 = \sqrt{3}/2 \approx 0.866$$

$$IQR = \sqrt{3} \approx 1.732$$

$$\text{Границы: } [-3.464, 3.464]$$

$$P_{\text{out}} = 0 \quad (\text{все значения внутри } [-\sqrt{3}, \sqrt{3}]) = \mathbf{0.0\%}$$

5.7 Сравнение экспериментальных и теоретических результатов

Таблица 1: Сравнение экспериментальных и теоретических долей выбросов (%)

Распределение	Эксперимент		Теория	Отклонение ($n=100$)
	$n=20$	$n=100$		
Нормальное	2.45%	1.00%	0.70%	+0.30%
Коши	14.68%	15.12%	15.60%	-0.48%
Лапласа	7.18%	6.70%	6.20%	+0.50%
Пуассона	2.25%	1.06%	0.70%	+0.36%
Равномерное	0.22%	0.00%	0.00%	0.00%

Анализ результатов:

- 1. Нормальное распределение:** Экспериментальные значения выше теоретических при малых n из-за случайных флуктуаций. При $n = 100$ отклонение составляет всего 0.3%, что подтверждает состоятельность оценки.
- 2. Распределение Коши:** Наилучшее согласие с теорией (15.12% против 15.6%). Небольшое занижение может быть связано с обрезанием экстремальных значений при генерации выборки.
- 3. Распределение Лапласа:** Хорошее согласие (6.70% против 6.2%). Небольшое завышение объясняется конечным объёмом выборки и случайными отклонениями.
- 4. Распределение Пуассона:** При $\lambda = 10$ распределение близко к нормальному, поэтому теоретическая доля близка к 0.7%. Экспериментальные значения сходятся к теории при увеличении n .
- 5. Равномерное распределение:** Идеальное согласие: при $n = 100$ экспериментальная доля выбросов равна 0%, что точно соответствует

теории. При $n = 20$ единичный выброс (0.22%) является статистической флуктуацией.

Влияние размера выборки:

- Для всех распределений отклонение экспериментальных значений от теоретических **уменьшается** при увеличении n с 20 до 100
- Это подтверждает **состоятельность** эмпирической оценки доли выбросов
- Стандартное отклонение оценок также уменьшается, что свидетельствует о повышении точности

Вывод: Экспериментальные результаты хорошо согласуются с теоретическими предсказаниями. Максимальное отклонение при $n = 100$ не превышает 0.5% , что подтверждает корректность реализации метода Тьюки и применимость эмпирических оценок для анализа выбросов.

5.8 Распределения с границами выбросов




Рис. 6: Гистограммы с границами выбросов Тьюки ($n=100$)

6. Обсуждение

6.1 Влияние типа распределения на долю выбросов

1. Нормальное распределение:

- Доля выбросов близка к теоретическим 0.7%
- Немного выше из-за случайных флуктуаций
- Стабильные результаты при увеличении n

2. Распределение Коши:

- Наибольшая доля выбросов (28-31%)
- Подтверждает наличие тяжёлых хвостов
- Доля выбросов не уменьшается с ростом n
- Это согласуется с отсутствием конечной дисперсии

3. Распределение Лапласа:

- Доля выбросов выше нормального (8-9%)
- Более тяжёлые хвосты, чем у нормального
- Но значительно меньше, чем у Коши

4. Распределение Пуассона:

- Низкая доля выбросов (3-4%)
- Дискретная природа распределения
- При $\lambda = 10$ приближается к нормальному

5. Равномерное распределение:

- Минимальная доля выбросов (0.1-0.3%)
- Все значения равновероятны
- Нет хвостов — нет выбросов

6.2 Влияние размера выборки

- При увеличении n с 20 до 100:
 - Доля выбросов стабилизируется
 - Уменьшается разброс оценок
 - Результаты становятся более надёжными
- Для Коши доля выбросов даже немного растёт — это связано с тем, что при больших выборках чаще попадаются экстремальные значения

6.3 Практическое применение

- Боксплот Тьюки — эффективный инструмент для быстрого обнаружения аномалий
- Позволяет визуально оценить:
 - Симметрию распределения
 - Наличие выбросов
 - Разброс данных
 - Положение медианы
- Метод робастен — не чувствителен к самим выбросам при вычислении границ

7. Выводы

1. Освоен метод построения боксплота Тьюки для визуализации и анализа одномерных распределений.
2. Показано, что доля выбросов существенно зависит от типа распределения:
 - Минимальная для равномерного распределения (0.1-0.3%)

- Близкая к теоретической для нормального (4-5%)
 - Максимальная для распределения Коши (28-31%)
3. Подтверждено, что распределение Коши имеет значительно более тяжёлые хвосты по сравнению с нормальным распределением.
 4. Установлено, что увеличение размера выборки приводит к стабилизации оценок доли выбросов.
 5. Боксплот Тьюки продемонстрировал свою эффективность как инструмент:
 - Быстрого обнаружения выбросов
 - Визуальной оценки распределения
 - Сравнения различных распределений
 6. Приобретены практические навыки работы с методами описательной статистики в Python.

8. Список литературы

1. Тьюки Дж. Разведочный анализ данных. — М.: Финансы и статистика, 1981.
2. Гмурман В.Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2003.
3. Кобецкая И.А. Математическая статистика. — СПб.: Лань, 2019.
4. SciPy documentation. URL: <https://docs.scipy.org/doc/scipy/>
5. Matplotlib documentation. URL: <https://matplotlib.org/>
6. Seaborn documentation. URL: <https://seaborn.pydata.org/>

9. Приложение

Исходный код программы размещён в репозитории GitHub:

`https://github.com/Ftp-Glich/Statistics`

В папке `results_lab3` находятся:

- `[distribution]_boxplots.png` — боксплоты для каждого распределения (5 файлов)
- `outlier_analysis.txt` — числовые результаты анализа выбросов
- `outlier_comparison.png` — сравнение средней доли выбросов
- `distributions_with_outliers.png` — гистограммы с границами выбросов
- `outlier_boxplots.png` — боксплоты долей выбросов (1000 повторений)