

Санкт-Петербургский политехнический университет
Петра Великого
Высшая школа прикладной математики и вычислительной
физики

Отчёт по лабораторной работе по дисциплине
«Математическая статистика»

ЛАБОРАТОРНАЯ РАБОТА №4
«Эмпирическая функция распределения и ядерные оценки
плотности»

Выполнил: Гуцалов Егор Никитич
Группа: 5030102/30201

Санкт-Петербург
2025

2. Постановка задачи

Цель работы: Изучить методы построения эмпирической функции распределения и ядерных оценок плотности, проанализировать влияние размера выборки на точность оценок, сравнить ядерные оценки с гистограммами.

Задачи:

- Сгенерировать выборки объёмом $n = 20, 60, 100$ для каждого из 5 распределений
- Построить эмпирическую функцию распределения (ЭФР) и теоретическую функцию распределения
- Построить ядерную оценку плотности (с гауссовым ядром) и теоретическую плотность
- Выполнить построение на отрезке $[-4, 4]$ для непрерывных распределений и на отрезке $[6, 14]$ для распределения Пуассона
- Проанализировать, как мощность выборки влияет на приближение эмпирической функции к истинной
- Сравнить два способа оценки плотности: ядерные оценки и гистограммы

Исследуемые распределения:

1. Нормальное $N(0, 1)$
2. Коши $C(0, 1)$
3. Лапласа $L(0, \frac{1}{\sqrt{2}})$
4. Пуассона $P(10)$
5. Равномерное $U(-\sqrt{3}, \sqrt{3})$

3. Теоретическая часть

3.1 Эмпирическая функция распределения

Эмпирическая функция распределения (ЭФР) — это ступенчатая функция, определяемая как доля элементов выборки, не превосходящих заданного значения x :

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x) \quad (1)$$

где $I(\cdot)$ — индикаторная функция, равная 1, если условие выполняется, и 0 иначе.

Свойства ЭФР:

- Неубывающая ступенчатая функция
- Принимает значения от 0 до 1
- Делает скачок величины $1/n$ в каждой точке выборки
- Состоятельная оценка истинной функции распределения

Теорема Гливенко-Кантелли:

$$\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{a.s.} 0 \quad (2)$$

Эта теорема утверждает, что эмпирическая функция распределения равномерно сходится к истинной функции распределения почти наверное.

3.2 Ядерная оценка плотности

Ядерная оценка плотности (Kernel Density Estimation, KDE) — это непараметрический метод оценки плотности вероятности, основанный на сглаживании данных.

В отличие от гистограммы, которая является ступенчатой функцией, ядерная оценка даёт **непрерывную гладкую оценку** плотности.

Формула ядерной оценки:

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (3)$$

где:

- $K(\cdot)$ — ядерная функция (в данной работе используется гауссово ядро)
- $h > 0$ — параметр сглаживания (bandwidth)

Гауссово ядро:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2} \quad (4)$$

Выбор параметра сглаживания h :

- Малое h — оценка следует за данными, может быть шумной (переобучение)
- Большое h — оценка слишком гладкая, может потерять детали (недообучение)
- В работе используется автоматический выбор h по правилу Скотта

3.3 Сравнение гистограммы и KDE

Таблица 1: Сравнение гистограммы и ядерной оценки плотности

Характеристика	Гистограмма	KDE
Гладкость	Ступенчатая функция	Непрерывная гладкая
Зависимость от параметров	Выбор границ и ширины бинов	Выбор параметра сглаживания h
Визуальное качество	Грубая, дискретная	Плавная, естественная
Вычислительная сложность	Низкая	Выше
Интерпретация	Простая	Требуется понимания ядер

4. Реализация

Язык программирования: Python 3.x

Используемые библиотеки:

- `numpy` — генерация случайных выборок и вычисления
- `matplotlib.pyplot` и `seaborn` — визуализация данных
- `scipy.stats` — теоретические распределения и гауссово ядро

Среда разработки: Visual Studio Code

Основные этапы реализации:

1. Генерация выборок объёмом $n = 20, 60, 100$ из каждого распределения
2. Построение эмпирической функции распределения (ступенчатый график)
3. Наложение теоретической функции распределения
4. Построение гистограммы выборки
5. Вычисление ядерной оценки плотности с гауссовым ядром
6. Наложение теоретической плотности
7. Сохранение графиков для всех распределений и размеров выборок

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy import stats
4 from scipy.stats import gaussian_kde
5
6 n = 100
7 sample = np.random.normal(0, 1, n)
8
9 x_ecdf = np.linspace(-4, 4, 1000)
10 y_ecdf = np.array([np.mean(sample <= xi)
11                     for xi in x_ecdf])
```

```

12
13 kde = gaussian_kde(sample)
14 y_kde = kde(x_ecdf)
15
16 y_theoretical_pdf = stats.norm.pdf(
17     x_ecdf, loc=0, scale=1)
18
19 plt.figure(figsize=(10, 6))
20 plt.hist(sample, bins='sqrt', density=True,
21     alpha=0.3, label='Histogram')
22 plt.plot(x_ecdf, y_kde, 'b-', linewidth=2,
23     label='Kernel Density')
24 plt.plot(x_ecdf, y_theoretical_pdf, 'r--',
25     linewidth=2, label='Theoretical')
26 plt.legend()
27 plt.show()

```

Листинг 1: Построение ЭФР и ядерной оценки плотности

5. Результаты

5.1 Нормальное распределение $N(0, 1)$




Рис. 1: Эмпирическая функция распределения для нормального закона




Рис. 2: Ядерная оценка плотности для нормального закона

Наблюдения:

- При $n = 20$ ЭФР заметно отклоняется от теоретической кривой
- При $n = 100$ наблюдается хорошее совпадение ЭФР с теорией
- KDE плавно приближается к теоретической плотности при росте n
- Гистограмма при малых n имеет разреженные бины

5.2 Распределение Коши $C(0, 1)$




Рис. 3: Эмпирическая функция распределения для закона Коши




Рис. 4: Ядерная оценка плотности для закона Коши

Наблюдения:

- Из-за тяжёлых хвостов наблюдаются значительные флуктуации
- KDE сглаживает выбросы, но может терять детали распределения
- Сходимость медленнее, чем для нормального распределения

5.3 Распределение Лапласа $L(0, 1/\sqrt{2})$




Рис. 5: Эмпирическая функция распределения для закона Лапласа




Рис. 6: Ядерная оценка плотности для закона Лапласа

Наблюдения:

- Острый пик в центре хорошо виден на KDE
- ЭФР демонстрирует более быстрый рост в центре
- При $n = 100$ оценка плотности близка к теоретической

5.4 Распределение Пуассона $P(10)$




Рис. 7: Эмпирическая функция распределения для закона Пуассона




Рис. 8: Ядерная оценка плотности для закона Пуассона

Наблюдения:

- Дискретная природа распределения видна на ступенчатой ЭФР
- KDE применяет сглаживание к дискретным данным
- При $\lambda = 10$ распределение приближается к нормальному

5.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$




Рис. 9: Эмпирическая функция распределения для равномерного закона




Рис. 10: Ядерная оценка плотности для равномерного закона

Наблюдения:

- Линейный рост ЭФР характерен для равномерного распределения
- KDE размывает резкие границы из-за сглаживания
- При больших n оценка приближается к прямоугольной форме

5.6 Сравнение всех распределений




Рис. 11: Сравнение ЭФР и KDE для всех распределений ($n = 100$)

5.7 Влияние параметра сглаживания h на ядерную оценку плотности

Параметр сглаживания (bandwidth) h в ядерной оценке плотности критически влияет на качество аппроксимации.

Формула KDE с параметром h :

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (5)$$

Эффект выбора h :

- **Малое h** (например, 0.1): оценка следует за каждой точкой выборки, возникает “шум” и переобучение
- **Большое h** (например, 1.0): оценка слишком гладкая, теряются детали распределения (недообучение)
- **Оптимальное h** : баланс между смещением и дисперсией оценки

Правило Скотта для автоматического выбора h :

$$h_{\text{Scott}} = 1.06 \cdot \hat{\sigma} \cdot n^{-1/5} \quad (6)$$

где $\hat{\sigma}$ — выборочное стандартное отклонение.

Сравнение оценок при разных h




Рис. 12: Сравнение KDE при разных значениях h для нормального распределения ($n = 100$)




Рис. 13: Сравнение KDE при разных значениях h для распределения Коши ($n = 100$)




Рис. 14: Сравнение KDE при разных значениях h для распределения Лапласа ($n = 100$)




Рис. 15: Сравнение KDE при разных значениях h для распределения Пуассона ($n = 100$)




Рис. 16: Сравнение KDE при разных значениях h для равномерного распределения ($n = 100$)




Рис. 17: Зависимость среднеквадратичной ошибки (MSE) от параметра h для нормального распределения

Наблюдения по каждому распределению:

1. Нормальное распределение $N(0, 1)$:

- При $h = 0.1$ оценка “зубчатая”, повторяет случайные флуктуации выборки
- При $h = 1.0$ оценка слишком гладкая, размывается пик
- Правило Скотта ($h \approx 0.4$) даёт хороший баланс
- Теоретическая кривая хорошо воспроизводится при оптимальном h

2. Распределение Коши $C(0, 1)$:

- Из-за тяжёлых хвостов малые h усиливают влияние выбросов
- Большие h сглаживают хвосты, но теряют информацию о форме
- Автоматический выбор h работает удовлетворительно
- Даже при оптимальном h оценка менее точна из-за высокой дисперсии выборки

3. Распределение Лапласа $L(0, 1/\sqrt{2})$:

- Острый пик в центре требует достаточно малого h для воспроизведения
- При больших h пик размывается, оценка становится похожей на нормальную
- Оптимальное h позволяет сохранить характерную форму с острым центром

4. Распределение Пуассона $P(10)$:

- Дискретная природа распределения делает KDE менее естественным методом
- Малые h создают “пики” в точках выборки
- Большие h сглаживают дискретность, приближая к непрерывной оценке
- Для дискретных данных гистограмма часто предпочтительнее KDE

5. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$:

- Прямоугольная форма плотности плохо воспроизводится гауссовым ядром
- Малые h дают “волнистую” оценку с артефактами на границах
- Большие h размывают резкие границы, создавая “колоколообразную” оценку
- Это фундаментальное ограничение гауссова ядра для распределений с разрывами

Анализ MSE (среднеквадратичной ошибки):

График 17 показывает зависимость $MSE = \mathbb{E}[(\hat{f}_h(x) - f(x))^2]$ от параметра h для нормального распределения:

- Кривая имеет **U-образную форму**: ошибка велика при очень малых и очень больших h

- **Минимум MSE** достигается вблизи значения по правилу Скотта
- Это подтверждает теоретическую оптимальность правила $h = 1.06 \cdot \sigma \cdot n^{-1/5}$
- Для других распределений форма кривой аналогична, но положение минимума может отличаться

Практические рекомендации:

- Начинать с автоматического выбора (h_{Scott} или $h_{\text{Silverman}}$)
- Визуально проверять результат: оценка должна быть гладкой, но сохранять основные особенности
- При наличии выбросов рассмотреть робастные методы оценки h
- Для сравнения распределений использовать одинаковый h
- Для дискретных данных или распределений с разрывами рассмотреть альтернативы KDE

6. Обсуждение

6.1 Влияние размера выборки

1. Эмпирическая функция распределения:

- При $n = 20$: заметные случайные отклонения от теоретической кривой
- При $n = 60$: улучшение сходимости, уменьшение флуктуаций
- При $n = 100$: хорошее согласие с теорией, подтверждение теоремы Гливленко-Кантелли

2. Ядерная оценка плотности:

- При малых n : оценка может быть шумной или слишком сглаженной

- При увеличении n : KDE всё лучше воспроизводит форму теоретической плотности
- Автоматический выбор параметра сглаживания работает удовлетворительно

6.2 Сравнение методов оценки плотности

Преимущества KDE перед гистограммой:

- Непрерывность и гладкость оценки
- Отсутствие зависимости от выбора границ бинов
- Лучшее визуальное восприятие формы распределения
- Более эффективное использование данных

Недостатки KDE:

- Вычислительная сложность выше
- Требуется выбор параметра сглаживания
- Может размывать резкие границы (для равномерного распределения)
- Менее интуитивна для интерпретации

6.3 Особенности различных распределений

1. **Нормальное:** быстрая сходимость, обе оценки работают хорошо
2. **Коши:** медленная сходимость из-за тяжёлых хвостов, KDE сглаживает выбросы
3. **Лапласа:** острый пик хорошо воспроизводится при достаточном n
4. **Пуассона:** дискретная природа требует осторожности при интерпретации KDE
5. **Равномерное:** KDE размывает границы, гистограмма лучше показывает прямоугольную форму

7. Выводы

1. Освоены методы построения эмпирической функции распределения и ядерных оценок плотности для анализа одномерных данных.
2. Подтверждена теорема Гливленко-Кантелли: с ростом объёма выборки эмпирическая функция распределения равномерно сходится к истинной функции распределения.
3. Показано, что ядерная оценка плотности даёт более гладкую и визуально приятную оценку по сравнению с гистограммой, не зависящую от выбора границ бинов.
4. Установлено, что скорость сходимости оценок зависит от типа распределения:
 - Быстрая сходимость для нормального и равномерного распределений
 - Медленная сходимость для распределения Коши из-за тяжёлых хвостов
5. Выявлено, что для дискретных распределений (Пуассона) применение KDE требует осторожности в интерпретации, так как метод предполагает непрерывность.
6. Приобретены практические навыки сравнительного анализа различных методов оценки плотности вероятности в Python.

8. Список литературы

1. Гмурман В.Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2003.
2. Кобецкая И.А. Математическая статистика: Учебное пособие. — СПб.: Лань, 2019.

3. Silverman B.W. Density Estimation for Statistics and Data Analysis. — Chapman and Hall, 1986.
4. SciPy documentation. URL: <https://docs.scipy.org/doc/scipy/>
5. Matplotlib documentation. URL: <https://matplotlib.org/>
6. Seaborn documentation. URL: <https://seaborn.pydata.org/>

9. Приложение

Исходный код программы размещён в репозитории GitHub:

<https://github.com/Ftp-Glich/Statistics>

В папке `results_lab4` находятся:

- `[distribution]_ecdf.png` — эмпирические функции распределения (5 файлов)
- `[distribution]_kde.png` — ядерные оценки плотности (5 файлов)
- `all_distributions_comparison.png` — сравнительный график для всех распределений