

Санкт-Петербургский политехнический университет
Петра Великого
Высшая школа прикладной математики и вычислительной физики

Отчёт по лабораторной работе по дисциплине
«Математическая статистика»

ЛАБОРАТОРНАЯ РАБОТА №6
«Линейная регрессия. Метод наименьших квадратов и наименьших
модулей»

Выполнил: Гуцалов Егор Никитич
Группа: 5030102/30201

Санкт-Петербург
2025

1 Постановка задачи

1.1 Цель работы

Освоить методы оценки параметров линейной регрессионной модели: метод наименьших квадратов (МНК) и метод наименьших модулей (МНМ). Исследовать устойчивость методов к наличию выбросов в данных.

1.2 Задачи

1. Сгенерировать выборку из модели $y = a + bx + \varepsilon$, где $a = 2$, $b = 2$, $\varepsilon \sim N(0, 1)$, $x \in [-1.8, 2.0]$ с шагом 0.2.
2. Оценить параметры a и b методами МНК и МНМ для «чистых» данных.
3. Добавить выбросы: $y_1 \leftarrow y_1 + 10$, $y_{20} \leftarrow y_{20} - 10$.
4. Повторить оценку параметров для данных с выбросами.
5. Сравнить точность и устойчивость методов через абсолютные и относительные погрешности.
6. Построить графики регрессии с истинной и оценённой зависимостями.

2 Теоретическая часть

2.1 Линейная регрессионная модель

Модель линейной регрессии имеет вид:

$$y_i = a + bx_i + \varepsilon_i, \quad i = 1, \dots, n \quad (1)$$

где a — свободный член, b — коэффициент наклона, ε_i — случайная ошибка.

2.2 Метод наименьших квадратов (МНК)

МНК находит оценки $\hat{a}$, $\hat{b}$, минимизируя сумму квадратов невязок:

$$Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2 \rightarrow \min_{a, b} \quad (2)$$

Аналитическое решение:

$$\hat{b} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x} \quad (3)$$

2.3 Метод наименьших модулей (МНМ)

МНМ минимизирует сумму модулей невязок:

$$S(a, b) = \sum_{i=1}^n |y_i - a - bx_i| \rightarrow \min_{a, b} \quad (4)$$

Не имеет аналитического решения; применяется численная оптимизация (метод Нелдера–Мида).

2.4 Погрешности оценок

Абсолютная погрешность:

$$\Delta_z = |z - \hat{z}| \quad (5)$$

Относительная погрешность (%):

$$\delta_z = \frac{\Delta_z}{z} \cdot 100\% \quad (6)$$

3 Реализация

3.1 Инструментарий

- Язык: Python 3.10+
- Библиотеки: NumPy, SciPy, Matplotlib
- Среда: VS Code / PyCharm

3.2 Основные функции

Генерация данных:

```
1 def generate_x_values(start=-1.8, end=2.0, step=0.2):
2     return np.arange(start, end + step, step)
3
4 def generate_y_values(x, a_true=2.0, b_true=2.0, sigma=1.0):
5     epsilon = np.random.normal(0, sigma, len(x))
6     return a_true + b_true * x + epsilon
```

МНК (аналитическое решение):

```
1 def least_squares_method(x, y):
2     x_mean, y_mean = np.mean(x), np.mean(y)
3     num = np.sum((x - x_mean) * (y - y_mean))
4     den = np.sum((x - x_mean) ** 2)
5     b_hat = num / den
6     a_hat = y_mean - b_hat * x_mean
7     return a_hat, b_hat
```

МНМ (численная оптимизация):

```
1 def least_absolute_deviations_method(x, y):
2     def objective(params):
3         a, b = params
4         return np.sum(np.abs(y - (a + b * x)))
5     result = minimize(objective, [0, 0], method='Nelder-Mead')
6     return result.x
```

Добавление выбросов:


```
1 def add_outliers(y, indices, values):
2     y_out = y.copy()
3     for idx, val in zip(indices, values):
4         y_out[idx] += val
5     return y_out
```

4 Результаты


4.1 Оценка параметров без выбросов

Таблица 1: Результаты оценки параметров без выбросов

Метод	a	Δ_a	$\delta_a, \%$	b	Δ_b	$\delta_b, \%$
МНК	1.8785	0.1215	6.08	1.5022	0.4978	24.89
МНМ	1.7093	0.2907	14.54	1.5625	0.4375	21.87



(a) МНК




(b) МНМ

Рис. 1: Регрессия без выбросов


4.2 Оценка параметров с выбросами

Таблица 2: Результаты оценки параметров с выбросами

Метод	a	Δ_a	$\delta_a, \%$	b	Δ_b	$\delta_b, \%$
МНК	2.0213	0.0213	1.07	0.0736	1.9264	96.32
МНМ	1.8174	0.1826	9.13	1.4070	0.5930	29.65



(a) МНК



(b) МНМ

Рис. 2: Регрессия с выбросами

4.3 Сравнение устойчивости

Таблица 3: Изменение оценок при добавлении выбросов

Метод	$ \Delta a $	$ \Delta b $	$\delta_a, \%$	$\delta_b, \%$
МНК	0.1429	1.4286	—	—
МНМ	0.1082	0.1556	—	—

5 Обсуждение результатов

5.1 Анализ без выбросов

Из таблицы 1 и рисунка 1:

1. **МНК** даёт меньшие погрешности для коэффициента a (6.08% против 14.54%), что согласуется с теоремой Гаусса–Маркова: МНК оптимален при нормальном шуме.
2. **МНМ** показывает сопоставимую точность для b (21.87% против 24.89%), но проигрывает для a .
3. Обе оценки смещены относительно истинных значений ($a = 2, b = 2$) из-за конечного объёма выборки ($n = 20$) и случайного шума.

5.2 Анализ с выбросами

Из таблицы 2 и рисунка 2:

1. **МНК** катастрофически теряет точность для b : погрешность выросла с 24.89% до 96.32%. На рисунке 2а видно, что оценённая прямая практически горизонтальна.
2. **МНМ** демонстрирует устойчивость: погрешность для b увеличилась с 21.87% до 29.65%, что значительно меньше, чем у МНК.
3. Для коэффициента a ситуация обратная: МНК неожиданно дал малую погрешность (1.07%), но это случайная компенсация ошибок, а не свойство метода.

5.3 Сравнение устойчивости

Из таблицы 3:

- Изменение b у МНК: $|\Delta b| = 1.4286$ (почти полное разрушение оценки)
- Изменение b у МНМ: $|\Delta b| = 0.1556$ (умеренное влияние)
- Для a оба метода показали сопоставимую устойчивость

Это подтверждает теоретическое свойство: МНМ робастен к выбросам, так как минимизирует сумму модулей, а не квадратов.

6 Выводы

1. МНК обеспечивает высокую точность при нормальном шуме и отсутствии выбросов, что подтверждается меньшими погрешностями в «чистом» случае.
2. МНМ менее точен при идеальных данных, но демонстрирует значительное преимущество при наличии выбросов.
3. Выбросы оказывают катастрофическое влияние на оценку коэффициента наклона b методом МНК: погрешность выросла с 24.89% до 96.32%.
4. МНМ устойчив к выбросам: погрешность оценки b увеличилась лишь с 21.87% до 29.65%.
5. При работе с реальными данными, где возможны аномалии, предпочтительно использовать робастные методы (МНМ) или предварительно очищать данные от выбросов.

Список литературы

1. Гмурман В.Е. Теория вероятностей и математическая статистика. — М.: Высшая школа, 2003.
2. Кобецкая И.А. Математическая статистика: Учебное пособие. — СПб.: Лань, 2019.
3. Huber P.J. Robust Statistics. — Wiley, 1981.
4. SciPy documentation. URL: <https://docs.scipy.org/doc/scipy/>
5. Matplotlib documentation. URL: <https://matplotlib.org/stable/contents.html>
6. NumPy documentation. URL: <https://numpy.org/doc/>

9. Приложение

Исходный код программы размещён в репозитории GitHub:

<https://github.com/Ftp-Glich/Statistics>